

Coursera week3

1. Motivation






- 파란색 class 0
- 빨간색 class 1

Linear Classification 모델 2가지를 만들어 냈다고 하면 어떤 모델을 사용해야 할까요?

If your model is scored with some metric, you get best results by optimizing exactly that metric

모델이 어떤

metric으로 점수가 매겨진다면, <u>그 metric</u>으로 최적화해야 최고의 결과를 얻을 수 있다.



이 컴피티션에서 Loss는

- 추세가 맞다면 (실제값 예측값)
- 추세가 틀리다면 (실제값 예측값) 의 제곱

Predict trend instead of the values:

Predict
$$y_{last} + 10^{-6}$$

or $y_{last} - 10^{-6}$

추세(trend)를 맞추기 위해 예측값들에 작은 상수를 더하거나 뺐다.

결론

컴피티션에서 요구한 metric 에 모델을 최적화하는 것이 리더보드에서 높은 랭커가 될 수 있는 방법이다.

2. Regression metrics

2-1. 공부할 내용


- MSE, RMSE, R-squared
- MΔF
- MSPE, MAPE
- (R)MSLE

Notation

- N number of objects
- $y \in \mathbb{R}^N$ target values $\hat{y} \in \mathbb{R}^N$ predictions
- $\hat{y}_i \in \mathbb{R}$ prediction for i-th object $y_i \in \mathbb{R}$ target for i-th object


2-2. MSE: Mean Square Error

Regression 문제에 대한 가장 일반적인 metric



만약에 모든 예측값을 하나로 통일한다면, 최소의 MSE를 얻기 위해 어떤 값으로 통일하는 게 좋을까요?

Best constant: target mean (11)



2-3. RMSE: Root Mean Square Error

MSE 의 제곱근 (루트 씌운것)

일반적으로 MSE 와 RMSE 는 동일하게 해석 가능

• RMSE =
$$\sqrt{\frac{1}{N} \sum_{i=1}^{N} (y_i - \hat{y}_i)^2} = \sqrt{\text{MSE}}$$

• $MSE(a) > MSE(b) \iff RMSE(a) > RMSE(b)$

하지만, gradient 기반 해석에서는 동일하지 않을 수 있다.?

•
$$\frac{\partial \text{RMSE}}{\partial \hat{y}_i} = \frac{1}{2\sqrt{MSE}} \frac{\partial \text{MSE}}{\partial \hat{y}_i}$$

MSE 가 어느정도 되어야 좋은 모델? 32? 0.4?


2-4. R-squared

MSE 점수를 0점에서 1점 사이로.

$$R^{2} = 1 - \frac{\frac{1}{N} \sum_{i=1}^{N} (y_{i} - \hat{y}_{i})^{2}}{\frac{1}{N} \sum_{i=1}^{N} (y_{i} - \bar{y})^{2}}$$

- MSE = 0 ==> R-squared = 1
- MSE = 상수모델의 MSE(R-zero) ==> R-squared = 0


Coefficient of Determination (R^2)




- The blue line represents the regression line
- The blue squares represents the MSE of the regression line
- The red line represents the average value of the data points
- The red squares represent the MSE of the red line
- We see the area of the blue squares is much smaller then the area of the red squares

Coefficient of Determination (R^2)

In this case ratio of the areas of MSE is close to zero




Coefficient of Determination (R^2)



2-5. MAE: Mean Absolute Error

Best constant: target median (8)



MAE 가 MSE 보다 robust 하다

2-6. MAE vs MSE

- Do you have outliers in the data?
 - Use MAE
- Are you sure they are outliers?
 - Use MAE
- Or they are just unexpected values we should still care about?
 - Use MSE


2-7. MSPE, MAPE

P: percentage

상대적 오류, MSE, MAE 의 가중치 버전


- **Shop 1**: predicted 9, sold 10, MSE = 1
- **Shop 2**: predicted 999, sold 1000, MSE = 1
- **Shop 1**: predicted 9, sold 10, MSE = 1
- **Shop 2**: predicted 900, sold 1000, MSE = 10000
- **Shop 1**: predicted 9, sold 10, relative_metric = 1
- **Shop 2**: predicted 900, sold 1000, relative_metric = 1

실제 1000개 판매량 중 999개로 예측한 것 보다 10개 판매량 중 9개로 예측한 것이 상대적으로 더 큰 오류




target 값이 클수록 MSPE, MAPE 완만하게 증가

MSPE's Best constant: weight target mean (6.6)



MSE's constant (11) 보다 작게 설정됨

MAPE's Best constant: weight target mean (6)




하지만 MSPE 나 MAPE 가 이상치에 대해 robust 한 metric 은 아니라고 설명. 오히려 아주아주 작은 이상치가 존재할 경우 작은 쪽으로 편향되어 best constant 가 설정될 수 있다.

2-8. (R)MSLE: Root Mean Square Logarithmic Error

RMSLE =
$$\sqrt{\frac{1}{N} \sum_{i=1}^{N} (\log(y_i + 1) - \log(\hat{y}_i + 1))^2} =$$

= $RMSE (\log(y_i + 1), \log(\hat{y}_i + 1)) =$
= $\sqrt{MSE (\log(y_i + 1), \log(\hat{y}_i + 1))}$

log 0 이 정의되지 않으므로 상수 더한다. 상수는 1이 아니라 임의의 수가 될 수 있다.



RMSLE 를 사용할 경우, target 값보다 높게 예측하는 것이 더 작은 RMSLE 값을 갖게 한다.

2-9. Wrap-up

Optimal constant 비교

Constant
11
9.11
8
6.6
6

- MSE: 큰 값에 대해 편향을 가진다
- MAE: 큰 값에 대해 MSE보다 적은 편향을 가진다.
- MSPE/MAPE: 작은 값에 대해 편향을 가진다.
- **RMSLE**: MAPE 보다 나은 metric 으로 여겨지는데, 작은 값에 대해 덜 편향적이고 상대적인 오류에 더 잘 작동하기 때문

3. Classification metrics

3-1. 공부할 내용

- Accuracy
- Logarithmic loss
- Area under ROC curve
- (Quadratic weighted) Kappa

Notation

- N is number of objects
- L is number of classes
- y ground truth
- \hat{y} predictions
- [a=b] indicator function
- Soft labels (soft predictions) are classifier's scores
- Hard labels (hard predictions):
 - $\arg\max_{i} f_i(x)$
 - [f(x) > b], b threshold
- Soft predictions
- Hard predictions
 - ㅇ multi class 문제에서는 argmax 로,
 - o binary class 문제에서는 threshold 로

3-2. Accuracy

전체 예측셋 중 ground truth 와 일치하는 예측셋의 비율

Hard predictions 필요

Best constant : 가장 많이 등장하는 class

Dataset:

- 10 cats
- 90 dogs

Predict always dog:

Accuracy = 0.9!

- Accuracy 는 직관적이지만 최적화 하는것은 어렵다.
- Accuracy 에서는 soft predictions 는 중요하지 않다.

3-3. Logarithmic loss (logloss)

Soft predictions 필요

Binary

Binary: $\operatorname{LogLoss} = -\frac{1}{N} \sum_{i=1}^{N} y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)$ $y_i \in \mathbb{R}, \quad \hat{y}_i \in \mathbb{R}$

• class(y_i) 가 0 또는 1이 있다고 생각

```
def logloss(true_label, predicted, eps=1e-15):
    p = np.clip(predicted, eps, 1-eps)
    if true_label == 1:
        return -log(p)
    else:
        return -log(1-p)
```

Multiclass

Multiclass:

$$LogLoss = -\frac{1}{N} \sum_{i=1}^{N} \sum_{i=1}^{L} y_{il} \log(\hat{y}_{il})$$
$$y_i \in \mathbb{R}^L, \quad \hat{y}_i \in \mathbb{R}^L$$

• In practice:

$$LogLoss = -\frac{1}{N} \sum_{i=1}^{N} \sum_{i=1}^{L} y_{il} \log(\min(\max(\hat{y}_{il}, 10^{-15}), 1 - 10^{-15}))$$

$$\operatorname{LogLoss} = -\frac{1}{N} \sum_{i=1}^{N} y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)$$

$$- \operatorname{Logloss}_{\text{Absolute error}}$$

$$2$$

$$0.0 \quad 0.2 \quad 0.4 \quad 0.6 \quad 0.8 \quad 1.0$$


$$\hat{y}$$

$$\operatorname{Logloss strongly penalizes completely wrong answers}$$


- logloss 는 완전히 잘못된 예측에 대해 더 많은 페널티를 부여
- 적게 잘못된 예측이 많은 모델이 더 좋은 점수를 받는다.

3-4. Area Under ROC Curve


ROC (Receiver Operating Characteristic)



<u>AUC (Area Under Curve)</u>



- binary task 에서만 사용
- 예측의 순서에 의존적



3-5. Kappa

Motivation

R-squared 와 비슷

Dataset:

10 cats

• 90 dogs

Baseline accuracy = 0.9

$$my_score = 1 - \frac{1 - accuracy}{1 - baseline}$$

- accuracy = 1
- accuracy = 0.9

my_score = 1

my score = 0

Kappa는 랜덤을 사용해 baseline 을 설정

Dataset:

- 10 cats
- 90 dogs

Predict 20 cats and 80 dogs at random: accuracy ~ 0.74

0.2*0.1 + 0.8*0.9 = 0.74

Cohen's Kappa =
$$1 - \frac{1 - \text{accuracy}}{1 - p_e}$$

 p_e — what accuracy would be on average, if we randomly permute our predictions

$$p_e = \frac{1}{N^2} \sum_{k} n_{k1} n_{k2}$$

해석: 무작위로 class를 예측했을때의 accuracy baseline

여기부터 이해가 잘 안됩니다...

Confusion matrix C

pred\ true	cat	dog	tiger
cat	4	2	3
dog	2	88	4
tiger	4	10	12

Weight matrix W

pred\ true	cat	dog	tiger
cat	0	1	10
dog	1	0	10
tiger	1	1	0

weighted error =
$$\frac{1}{const} \sum_{i,j} C_{ij} W_{ij}$$

weighted kappa = $1 - \frac{\text{weighted error}}{\text{weighted baseline error}}$

Quadratic and Linear Weighted Kappa

Linear weights

pred\ true	1	2	3
1	0	1	2
2	1	0	1
3	2	1	0

Quadratic weights

pred\ true	1	2	3
1	0	1	4
2	1	0	1
3	4	1	0

$$w_{ij} = |i - j|$$

$$w_{ij} = (i - j)^2$$

weighted kappa =
$$1 - \frac{\text{weighted error}}{\text{weighted baseline error}}$$